

ANALYSTLAB AFRICA

Data Analytics Internship Programme – Week 4 HealthConnect Clinic – Data Dictionary Review Notes

Prepared by Richard GNALOU | AnalystLab Africa BI Internship

Purpose

This document records the review of HealthConnect_Data_Dictionary.xlsx, one of the two primary resources for the Data Analytics track, and confirms it is aligned with the actual dataset before any analysis was carried out.

1. Resource Cross-Check

Every variable listed in the data dictionary was checked against the columns present in HealthConnect_Appointment_Data.csv. The result: all 18 columns in the dataset are documented in the dictionary, and all 18 entries in the dictionary match a column in the dataset. No undocumented field and no missing field were found.

2. Variable-by-Variable Notes

The table below summarises each variable and the specific rule or note attached to it in the dictionary, which directly shaped the data quality checks performed in the analysis notebook.

Variable	Type	Note from Data Dictionary	How it was used in Week 4
appointment_id	Text	Primary key	Verified as unique, no duplicates found.
patient_id	Text	May appear across multiple appointments	Confirmed: up to 9 appointments for the same patient.
gender	Text	Synthetic and anonymised	Reviewed distribution only, no quality issue.
age	Integer	Adult patients only	Verified: all values between 18 and 80.
age_group	Text	Provided for descriptive analysis	Cross-checked against age, fully consistent.
appointment_type	Text	Four appointment categories	Confirmed: exactly four categories present.
booking_date	Date	ISO format	Parsed successfully for all rows.
appointment_date	Date	ISO format	Parsed successfully; checked against booking_date for ordering.
appointment_day	Text	Derived from appointment date	Cross-checked against the actual weekday, fully consistent.

Variable	Type	Note from Data Dictionary	How it was used in Week 4
appointment_time	Text	Morning, Afternoon, Evening	Confirmed: only these three values present.
booking_lead_days	Integer	Provided and derivable	Cross-checked against the computed date difference, fully consistent.
previous_appointments	Integer	Synthetic historical count	Used as the basis for the previous_no_shows consistency check.
previous_no_shows	Integer	Cannot exceed historical appointments	Verified: rule holds in 100% of rows.
reminder_sent	Text	Yes or No	Used to validate reminder_channel logic.
reminder_channel	Text	None when no reminder was sent	Verified: missing values (27.32%) match exactly the "No" cases of reminder_sent.
distance_to_clinic_km	Decimal	Contains limited missing values	Confirmed: 1.80% missing, consistent with the note.
waiting_time_minutes	Integer	Contains limited missing values	Confirmed: 1.20% missing, consistent with the note.
appointment_outcome	Text	Attended, No-Show, Cancelled	Confirmed: only these three values present.

3. Key Takeaways

- The dictionary's business rules (previous_no_shows, reminder_channel logic, adult-only age range) were used directly to design the logical consistency checks in the Data Quality Assessment, rather than being treated as background information only.
- No discrepancy was found between what the dictionary describes and what the dataset actually contains, which gives confidence in the reliability of the dataset for the next analysis phases.
- The dictionary does not document the duplicate patient/date/time-slot bookings found during analysis (Section 2 of the Initial Analysis Document); this is a genuine dataset anomaly outside of what the dictionary specifies, and is tracked separately as a risk.

Objectif

Ce document consigne la revue du fichier `HealthConnect_Data_Dictionary.xlsx`, l'une des deux ressources principales de la piste Data Analytics, et confirme son alignement avec le dataset réel avant le début de toute analyse.

1. Contrôle Croisé des Ressources

Chaque variable listée dans le data dictionary a été vérifiée par rapport aux colonnes présentes dans `HealthConnect_Appointment_Data.csv`. Résultat : les 18 colonnes du dataset sont toutes documentées dans le dictionnaire, et les 18 entrées du dictionnaire correspondent toutes à une colonne du dataset. Aucun champ non documenté ni aucun champ manquant n'a été trouvé.

2. Notes Variable par Variable

Le tableau ci-dessous résume chaque variable et la règle ou note spécifique qui lui est associée dans le dictionnaire, laquelle a directement guidé les contrôles de qualité réalisés dans le notebook d'analyse.

Variable	Type	Note du Data Dictionary	Utilisation en Semaine 4
appointment_id	Texte	Clé primaire	Vérifiée comme unique, aucun doublon trouvé.
patient_id	Texte	Peut apparaître dans plusieurs rendez-vous	Confirmé : jusqu'à 9 rendez-vous pour un même patient.
gender	Texte	Synthétique et anonymisé	Distribution seulement examinée, aucun problème de qualité.
age	Entier	Patients adultes uniquement	Vérifié : toutes les valeurs entre 18 et 80 ans.
age_group	Texte	Fourni pour l'analyse descriptive	Vérifié par rapport à age, entièrement cohérent.
appointment_type	Texte	Quatre catégories de rendez-vous	Confirmé : exactement quatre catégories présentes.
booking_date	Date	Format ISO	Analysée avec succès pour toutes les lignes.
appointment_date	Date	Format ISO	Analysée avec succès ; vérifiée par rapport à booking_date pour l'ordre chronologique.
appointment_day	Texte	Dérivé de la date du rendez-vous	Vérifié par rapport au jour réel de la semaine, entièrement cohérent.
appointment_time	Texte	Morning, Afternoon, Evening	Confirmé : seules ces trois valeurs sont présentes.

Variable	Type	Note du Data Dictionary	Utilisation en Semaine 4
booking_lead_days	Entier	Fourni et calculable	Vérifié par rapport à l'écart de dates calculé, entièrement cohérent.
previous_appointments	Entier	Comptage historique synthétique	Utilisé comme base pour le contrôle de cohérence de previous_no_shows.
previous_no_shows	Entier	Ne peut pas dépasser l'historique des rendez-vous	Vérifié : la règle est respectée dans 100% des lignes.
reminder_sent	Texte	Yes ou No	Utilisé pour valider la logique de reminder_channel.
reminder_channel	Texte	Vide si aucun rappel n'a été envoyé	Vérifié : les valeurs manquantes (27,32%) correspondent exactement aux cas "No" de reminder_sent.
distance_to_clinic_km	Décimal	Contient des valeurs manquantes limitées	Confirmé : 1,80% de valeurs manquantes, cohérent avec la note.
waiting_time_minutes	Entier	Contient des valeurs manquantes limitées	Confirmé : 1,20% de valeurs manquantes, cohérent avec la note.
appointment_outcome	Texte	Attended, No-Show, Cancelled	Confirmé : seules ces trois valeurs sont présentes.

3. Points Clés à Retenir

- Les règles métier du dictionnaire (previous_no_shows, logique de reminder_channel, tranche d'âge adulte) ont été utilisées directement pour concevoir les contrôles de cohérence logique dans l'Évaluation de la Qualité des Données, plutôt que d'être traitées comme une simple information de contexte.
- Aucun écart n'a été trouvé entre ce que décrit le dictionnaire et ce que contient réellement le dataset, ce qui donne confiance dans la fiabilité du dataset pour les phases d'analyse suivantes.
- Le dictionnaire ne documente pas les doubles réservations patient/date/créneau trouvées durant l'analyse (Section 2 du Document d'Analyse Initiale) ; il s'agit d'une véritable anomalie du dataset en dehors de ce que précise le dictionnaire, suivie séparément comme un risque.