

ANALYSTLAB AFRICA

Data Analytics Internship Programme – Week 4

HealthConnect Clinic – Initial Analysis Document

Prepared by Richard GNALOU | AnalystLab Africa BI Internship

Central Project Question

How can HealthConnect Clinic use data and AI to reduce missed appointments and improve the patient support experience?

1. Dataset Overview

The dataset `HealthConnect_Appointment_Data.csv` contains 5,000 appointment records across 18 columns. Each row represents one appointment. The `appointment_id` field is unique for every row (confirmed, no duplicates), while `patient_id` can repeat, since the same patient may book multiple appointments (up to 9 in this dataset).

The key outcome variable is `appointment_outcome`, split into three categories:

- No-Show: 48.46%
- Attended: 46.28%
- Cancelled: 5.26%

Nearly one appointment in two is missed, confirming the scale of the business problem described in the project scenario.

The dataset also includes demographic variables (gender, age, age_group), booking variables (booking_date, appointment_date, booking_lead_days), historical variables (previous_appointments, previous_no_shows), reminder variables (reminder_sent, reminder_channel), and logistic variables (distance_to_clinic_km, waiting_time_minutes).

Every column in the dataset is documented in the `HealthConnect_Data_Dictionary.xlsx`, and every dictionary entry matches a dataset column: the two resources are aligned.

2. Data Quality Assessment

A structural, logical, and cross-field consistency check was performed, not just a missing-value count.

Missing values are limited to three fields: `reminder_channel` (27.32%, expected since it is only populated when a reminder was sent), `distance_to_clinic_km` (1.80%), and `waiting_time_minutes` (1.20%). This matches the data dictionary's note of "limited missing values" for the last two fields.

Structural integrity: no duplicate `appointment_id` values and no fully duplicated rows.

Logical business rules: all hold correctly. `previous_no_shows` never exceeds `previous_appointments`, `booking_lead_days` is never negative, `reminder_channel` is

populated if and only if reminder_sent = Yes, and all patients fall within an adult age range (18 to 80).

Derived-field consistency: age_group always matches the value derived from age, appointment_day always matches the actual weekday of appointment_date, and booking_lead_days always equals the exact day difference between booking_date and appointment_date. No dates are out of order and none are unparseable.

Anomaly identified: 18 rows (9 distinct patient/date/time-slot groups) show the same patient with two different appointment IDs on the same date and same time slot, sometimes with different appointment types and different outcomes. For example, patient P-0039 has one Attended Diagnostic Test and one No-Show General Consultation, both on 3/15/2025 in the Morning slot. This could reflect a legitimate double booking for two different services, or a data generation artefact. It is flagged as a risk for any downstream modelling that assumes one appointment per patient per slot, and should be clarified before deeper analysis.

3. Relevant Business Questions

1. What is the overall no-show rate, and how does it vary across appointment types, time slots, and days of the week?
2. Which patient or booking characteristics (age group, distance to clinic, booking lead time, previous no-show history) are most associated with missed appointments?
3. Does sending a reminder, and which channel (SMS, WhatsApp, Email), correlate with a lower no-show rate?
4. How much appointment capacity is lost to no-shows and cancellations combined, and does this vary by appointment type or time of day?
5. Do longer waiting times or booking lead times correlate with a higher likelihood of no-show or cancellation?

4. Potential KPIs

Each KPI is linked to a business question. Although the assignment only requires KPIs to be identified and justified at this stage, they were explored with real figures to ensure each one is genuinely grounded in the data.

#	KPI	Linked Question	Justification and initial finding
1	No-Show Rate (%)	Q1	Overall rate is 48.46%. Varies modestly by appointment type (Follow-up highest at 51.2%, General Consultation lowest at 46.6%) and by day (Sunday 50.5% vs. Friday 46.6%), a narrow spread of about 5 points.
2	No-Show Rate by Reminder Status/Channel	Q3	Patients with no reminder no-show at 51.4% vs. 47.4% when a reminder was sent, a moderate effect of about 4 points. SMS performs best (45.75% no-show) compared to WhatsApp (49.77%) and Email (48.41%).

#	KPI	Linked Question	Justification and initial finding
3	Repeat No-Show Rate	Q2	Patients with a history of no-shows no-show again at 55.4%, vs. 43.5% for those with no prior no-shows: an 11.9-point gap, the strongest signal found in this exploration.
4	Lost Appointment Capacity Rate (No-Show + Cancelled)	Q4	53.72% of all appointments end in No-Show or Cancelled. This stays consistently high across appointment types (51.7% to 56.7%) and time slots (53.1% to 55.2%), suggesting a systemic issue.
5	Average Distance / Waiting Time / Booking Lead Time by Outcome	Q2, Q5	Distance and waiting time show almost no difference between outcomes: weak signals. Booking lead time is more notable: No-Shows book 34.5 days ahead on average vs. 24.5 days for Attended, a 10-day gap.

Overall takeaway: the strongest signals found are prior no-show history, reminder status/channel, and booking lead time. Distance and waiting time appear to have little standalone relationship with attendance in this dataset. These are correlational observations from cross-tabs, not statistically tested or causal conclusions, and should be validated further in the next phase.

5. Initial Analysis Approach

1. Prioritise the three strongest signals for deeper statistical validation: previous no-show history, reminder status/channel, and booking lead time.
2. Quantify formally with correlation coefficients or a simple logistic regression, rather than relying on descriptive cross-tabs alone.
3. Build segment-level dashboards to visualise no-show and lost-capacity rates by appointment type, day, and time slot, supporting operational decisions such as an overbooking policy for high-risk slots.
4. Investigate the duplicate-booking anomaly with the clinic/data source before drawing firm conclusions from the affected records.
5. Align with the Data Science track so the no-show prediction model builds on the same validated signals, avoiding duplicated exploration.
6. Document and iterate as new data or clarifications become available.

6. Assumptions, Limitations, Risks and Dependencies

Data limitations:

- The dataset is synthetic and anonymised; patterns found may not generalise to a real clinic.
- No cost or revenue data is available, so the financial impact of no-shows cannot yet be quantified, only counts and rates.
- Missing values in `reminder_channel`, `distance_to_clinic_km`, and `waiting_time_minutes` are limited but should be handled explicitly (exclude vs. impute) before deeper statistical modelling.

- The duplicate-booking anomaly (9 groups, 18 rows) remains unresolved and is flagged as a risk for downstream modelling.
- Cancelled and No-Show are distinct outcomes with likely different causes (a cancellation is a deliberate patient action, a no-show is not); combining them into a single "lost capacity" KPI is useful operationally but should not obscure this difference later.
- All relationships found in Section 4 are correlational, observed in cross-tabs, with no statistical significance testing or control for confounding variables performed yet.

Project dependencies and scope:

- This analysis lays groundwork the Data Science track will build on for no-show prediction; findings should be shared and aligned to avoid duplicated exploration.
- Week 4 is scoped to understanding and planning; formal visualisation and statistical testing are deferred to later weeks, per the assignment's explicit scope.

Question Centrale du Projet

Comment la Clinique HealthConnect peut-elle utiliser la donnée et l'IA pour réduire les rendez-vous manqués et améliorer l'expérience patient ?

1. Aperçu du Dataset

Le dataset `HealthConnect_Appointment_Data.csv` contient 5 000 enregistrements de rendez-vous répartis sur 18 colonnes. Chaque ligne représente un rendez-vous. Le champ `appointment_id` est unique pour chaque ligne (confirmé, aucun doublon), tandis que `patient_id` peut se répéter, car un même patient peut réserver plusieurs rendez-vous (jusqu'à 9 dans ce dataset).

La variable clé est `appointment_outcome`, répartie en trois catégories :

- No-Show : 48,46%
- Attended (présent) : 46,28%
- Cancelled (annulé) : 5,26%

Près d'un rendez-vous sur deux est manqué, ce qui confirme l'ampleur du problème business décrit dans le scénario du projet.

Le dataset comprend également des variables démographiques (`gender`, `age`, `age_group`), de réservation (`booking_date`, `appointment_date`, `booking_lead_days`), historiques (`previous_appointments`, `previous_no_shows`), de rappel (`reminder_sent`, `reminder_channel`), et logistiques (`distance_to_clinic_km`, `waiting_time_minutes`).

Chaque colonne du dataset est documentée dans le `HealthConnect_Data_Dictionary.xlsx`, et chaque entrée du dictionnaire correspond à une colonne du dataset : les deux ressources sont alignées.

2. Évaluation de la Qualité des Données

Un contrôle de structure, de logique métier et de cohérence croisée entre les champs a été réalisé, pas seulement un simple comptage des valeurs manquantes.

Valeurs manquantes : elles se limitent à trois champs : `reminder_channel` (27,32%, normal car rempli uniquement quand un rappel a été envoyé), `distance_to_clinic_km` (1,80%), et `waiting_time_minutes` (1,20%). Cela correspond à la note du data dictionary sur des "valeurs manquantes limitées" pour ces deux derniers champs.

Intégrité structurelle : aucun doublon sur `appointment_id`, ni ligne entièrement dupliquée.

Règles métier logiques : toutes sont respectées. `previous_no_shows` ne dépasse jamais `previous_appointments`, `booking_lead_days` n'est jamais négatif, `reminder_channel` est rempli si et seulement si `reminder_sent` = Yes, et tous les patients sont dans une fourchette d'âge adulte (18 à 80 ans).

Cohérence des champs dérivés : age_group correspond toujours à la valeur dérivée de age, appointment_day correspond toujours au jour réel de la semaine de appointment_date, et booking_lead_days est toujours égal à l'écart exact de jours entre booking_date et appointment_date. Aucune date n'est incohérente ou illisible.

Anomalie identifiée : 18 lignes (9 groupes distincts patient/date/créneau) montrent le même patient avec deux appointment_id différents à la même date et au même créneau horaire, parfois avec des types de rendez-vous et des issues différentes. Par exemple, le patient P-0039 a un Diagnostic Test "Attended" et une General Consultation "No-Show", tous deux le 15/03/2025 le matin. Cela peut refléter soit une double réservation légitime pour deux services distincts, soit un artefact de génération des données. Ce point est signalé comme un risque pour toute modélisation en aval qui suppose un seul rendez-vous par patient et par créneau, et devrait être clarifié avant une analyse plus poussée.

3. Questions Business Pertinentes

1. Quel est le taux global de no-show, et comment varie-t-il selon le type de rendez-vous, le créneau horaire et le jour de la semaine ?
2. Quelles caractéristiques du patient ou de la réservation (tranche d'âge, distance à la clinique, délai de réservation, historique de no-shows) sont les plus associées aux rendez-vous manqués ?
3. L'envoi d'un rappel, et quel canal (SMS, WhatsApp, Email), est-il corrélé à un taux de no-show plus faible ?
4. Quelle proportion de capacité de rendez-vous est perdue à cause des no-shows et des annulations combinés, et cela varie-t-il selon le type de rendez-vous ou le moment de la journée ?
5. Des temps d'attente ou des délais de réservation plus longs sont-ils corrélés à une probabilité plus élevée de no-show ou d'annulation ?

4. KPIs Potentiels

Chaque KPI est relié à une question business. Bien que la consigne exige seulement d'identifier et de justifier les KPIs à ce stade, ils ont été explorés avec des chiffres réels pour s'assurer que chacun est réellement ancré dans les données.

#	KPI	Question liée	Justification et constat initial
1	Taux de No-Show (%)	Q1	Le taux global est de 48,46%. Il varie modestement selon le type de rendez-vous (Follow-up le plus élevé à 51,2%, General Consultation le plus bas à 46,6%) et selon le jour (dimanche 50,5% vs. vendredi 46,6%), un écart faible d'environ 5 points.
2	Taux de No-Show par statut/canal de rappel	Q3	Les patients sans rappel font un no-show à 51,4% contre 47,4% quand un rappel a été envoyé, un effet modéré d'environ 4 points. Le SMS performe le mieux (45,75% de no-show) comparé à WhatsApp (49,77%) et à l'Email (48,41%).

#	KPI	Question liée	Justification et constat initial
3	Taux de récurrence de No-Show	Q2	Les patients ayant un historique de no-shows refont un no-show à 55,4%, contre 43,5% pour ceux sans antécédent : un écart de 11,9 points, le signal le plus fort trouvé dans cette exploration.
4	Taux de capacité perdue (No-Show + Annulés)	Q4	53,72% de tous les rendez-vous se terminent en No-Show ou Annulation. Ce taux reste élevé de façon homogène selon les types de rendez-vous (51,7% à 56,7%) et les créneaux (53,1% à 55,2%), suggérant un problème systémique.
5	Distance / Temps d'attente / Délai de réservation moyens par issue	Q2, Q5	La distance et le temps d'attente montrent presque aucune différence entre les issues : signaux faibles. Le délai de réservation est plus notable : les No-Shows réservent en moyenne 34,5 jours à l'avance contre 24,5 jours pour les Attended, un écart de 10 jours.

Conclusion générale : les signaux les plus forts trouvés sont l'historique de no-show antérieur, le statut/canal de rappel, et le délai de réservation. La distance et le temps d'attente semblent avoir peu de lien direct avec la présence dans ce dataset. Ce sont des observations corrélationnelles issues de tableaux croisés, non testées statistiquement et non causales, qui devront être validées plus rigoureusement lors de la phase suivante.

5. Approche d'Analyse Initiale

1. Prioriser les trois signaux les plus forts pour une validation statistique plus poussée : historique de no-show antérieur, statut/canal de rappel, et délai de réservation.
2. Quantifier formellement avec des coefficients de corrélation ou une régression logistique simple, plutôt que de se fier uniquement aux tableaux croisés descriptifs.
3. Construire des tableaux de bord par segment pour visualiser les taux de no-show et de capacité perdue par type de rendez-vous, jour et créneau horaire, afin d'appuyer des décisions opérationnelles comme une politique de surbooking sur les créneaux à risque.
4. Investiguer l'anomalie de double réservation avec la clinique/source de données avant de tirer des conclusions fermes sur les enregistrements concernés.
5. S'aligner avec la piste Data Science pour que le modèle de prédiction de no-show s'appuie sur les mêmes signaux validés, en évitant une exploration redondante.
6. Documenter et itérer au fur et à mesure que de nouvelles données ou clarifications sont disponibles.

6. Hypothèses, Limites, Risques et Dépendances

Limites liées aux données :

- Le dataset est synthétique et anonymisé ; les tendances observées peuvent ne pas se généraliser à une vraie clinique.
- Aucune donnée de coût ou de revenu n'est disponible, donc l'impact financier des no-shows ne peut pas encore être quantifié, seulement les comptages et taux.

- Les valeurs manquantes dans `reminder_channel`, `distance_to_clinic_km`, et `waiting_time_minutes` sont limitées mais devront être traitées explicitement (exclusion vs. imputation) avant une modélisation statistique plus poussée.
- L'anomalie de double réservation (9 groupes, 18 lignes) reste non résolue et est signalée comme un risque pour la modélisation en aval.
- Annulé et No-Show sont des issues distinctes avec probablement des causes différentes (une annulation est une action délibérée du patient, un no-show ne l'est pas) ; les combiner dans un seul KPI de "capacité perdue" est utile opérationnellement mais ne doit pas masquer cette différence par la suite.
- Toutes les relations trouvées en Section 4 sont corrélationnelles, observées dans des tableaux croisés, sans test de significativité statistique ni contrôle des facteurs de confusion réalisé pour l'instant.

Dépendances et périmètre du projet :

- Cette analyse pose les bases sur lesquelles la piste Data Science s'appuiera pour la prédiction des no-shows ; les résultats devront être partagés et alignés pour éviter une exploration redondante.
- La Semaine 4 se limite à la compréhension et à la planification ; la visualisation formelle et les tests statistiques sont reportés aux semaines suivantes, conformément au périmètre explicite de la consigne.