

ANALYSTLAB AFRICA

Data Analytics Internship Programme – Week 4 HealthConnect Clinic – Week 4 Project Summary

Prepared by Richard GNALOU | AnalystLab Africa BI Internship

1. Problem Addressed

This track investigates the appointment dataset to understand the scale and drivers of missed appointments (no-shows) at HealthConnect Clinic, and to propose business questions and KPIs that can guide decisions to reduce them and improve the patient support experience.

2. Resources Used

- HealthConnect_Appointment_Data.csv: 5,000 appointment records, 18 variables.
- HealthConnect_Data_Dictionary.xlsx: variable definitions and business rules, used to validate the dataset and design the quality checks. The Clinic Knowledge Base document was not used, as it is scoped to the Generative AI track.

3. Key Observations

- The overall no-show rate is 48.46%, close to one appointment in two, with cancellations adding another 5.26% (total lost capacity: 53.72%).
- The dataset is structurally clean: no missing primary keys, no duplicate rows, and all logical business rules (from the data dictionary) hold correctly.
- One data anomaly was identified: 9 cases where the same patient has two different appointment records on the same date and time slot, which needs clarification before use in predictive modelling.
- Three signals stand out as the most associated with attendance: prior no-show history (11.9-point gap between patients with and without a no-show history), reminder status and channel (SMS performs best), and booking lead time (No-Shows book about 10 days further in advance on average). Distance to clinic and waiting time show little standalone relationship with attendance in this dataset.

4. Proposed Approach

Five business questions and five KPIs were defined and linked to each other, covering overall no-show patterns, patient/booking risk factors, reminder effectiveness, lost capacity, and logistic factors. Each KPI was explored with real figures from the dataset (not just conceptually) to confirm it is grounded in an actual pattern before being carried into later phases.

5. Key Considerations

- Findings are correlational, not causal, and are based on synthetic data; they should not be treated as final conclusions.
- The duplicate-booking anomaly and the missing values in a few fields need a documented handling decision before deeper modelling.
- This work is a direct input to the Data Science track, which will build the no-show prediction model on these same signals.

6. Proposed Focus for Week 5

- Run formal statistical validation (correlation analysis or a simple logistic regression) on the three strongest signals identified.
- Build segment-level visualisations of no-show and lost-capacity rates.
- Clarify the duplicate-booking anomaly with the project source before it affects further analysis.
- Align findings with the Data Science track to avoid duplicated exploration.

1. Problème Traité

Cette piste explore le dataset des rendez-vous afin de comprendre l'ampleur et les facteurs des rendez-vous manqués (no-shows) à la Clinique HealthConnect, et de proposer des questions business et des KPIs qui pourront guider les décisions visant à les réduire et à améliorer l'expérience patient.

2. Ressources Utilisées

- HealthConnect_Appointment_Data.csv : 5 000 enregistrements de rendez-vous, 18 variables.
- HealthConnect_Data_Dictionary.xlsx : définitions des variables et règles métier, utilisées pour valider le dataset et concevoir les contrôles de qualité.

Le document Knowledge Base de la clinique n'a pas été utilisé, car il est destiné à la piste Generative AI.

3. Observations Clés

- Le taux global de no-show est de 48,46%, proche d'un rendez-vous sur deux, avec les annulations ajoutant 5,26% supplémentaires (capacité totale perdue : 53,72%).
- Le dataset est structurellement propre : aucune clé primaire manquante, aucune ligne dupliquée, et toutes les règles métier logiques (issues du data dictionary) sont respectées.
- Une anomalie de données a été identifiée : 9 cas où le même patient a deux enregistrements de rendez-vous différents à la même date et au même créneau, ce qui nécessite une clarification avant toute utilisation en modélisation prédictive.
- Trois signaux ressortent comme les plus associés à la présence : l'historique de no-show antérieur (écart de 11,9 points entre patients avec et sans antécédent), le statut et le canal de rappel (le SMS performe le mieux), et le délai de réservation (les No-Shows réservent environ 10 jours plus à l'avance en moyenne). La distance à la clinique et le temps d'attente montrent peu de lien direct avec la présence dans ce dataset.

4. Approche Proposée

Cinq questions business et cinq KPIs ont été définis et reliés entre eux, couvrant les tendances globales de no-show, les facteurs de risque liés au patient/à la réservation, l'efficacité des rappels, la capacité perdue, et les facteurs logistiques. Chaque KPI a été exploré avec des chiffres réels du dataset (pas seulement de façon conceptuelle) pour confirmer qu'il repose sur une tendance réelle avant d'être porté dans les phases suivantes.

5. Considérations Clés

- Les résultats sont corrélationnels, non causaux, et basés sur des données synthétiques ; ils ne doivent pas être considérés comme des conclusions définitives.

- L'anomalie de double réservation et les valeurs manquantes dans quelques champs nécessitent une décision de traitement documentée avant une modélisation plus poussée.
- Ce travail constitue un intrant direct pour la piste Data Science, qui construira le modèle de prédiction de no-show sur ces mêmes signaux.

6. Focus Proposé pour la Semaine 5

- Réaliser une validation statistique formelle (analyse de corrélation ou régression logistique simple) sur les trois signaux les plus forts identifiés.
- Construire des visualisations par segment des taux de no-show et de capacité perdue.
- Clarifier l'anomalie de double réservation avec la source du projet avant qu'elle n'affecte l'analyse ultérieure.
- Aligner les résultats avec la piste Data Science pour éviter une exploration redondante.